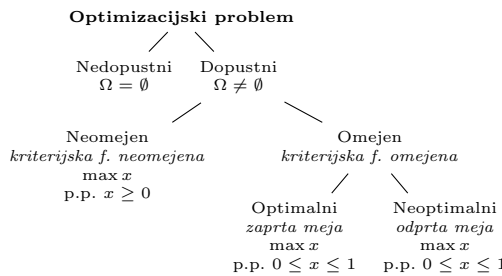


Optimizacijske naloge

Optimizacijska naloga je $(\Omega, f, \max/\min/\sup/\inf,)$ kjer je:

- Ω množica dopustnih rešitev
- $f : \Omega \rightarrow \mathbb{R}$ kriterijska funkcija

$x^* \in \Omega$ je *optimalna* rešitev problema (Ω, f, \max) , če velja $\forall x \in \Omega : f(x) \leq f(x^*)$



Linearno programiranje

$(\Omega, f, \min/\max)$ je linearni porgram, če je Ω podana z linearnimi enakostmi in neenakostmi (\leq, \geq) in je f linearna.

Standardna oblika linearnega programa

Linearni porgram je v *standardni* obliki, če iščemo \max in so vsi pogoji neenakosti \leq in so vse spremenljivke nenegativne.

$$\begin{array}{ll} \max & c_1x_1 + \dots + c_nx_n \\ \text{p.p.} & a_{11}x_1 + \dots + a_{1n}x_n \leq b_1 \\ & \vdots \\ & a_{m1}x_1 + \dots + a_{mn}x_n \leq b_m \\ & x_1, \dots, x_n \geq 0 \end{array}$$

To lahko zapišemo v matrični obliki:

$$c = [c_1 \dots c_n]^T \quad b = [b_1 \dots b_m]^T \quad x = [x_1 \dots x_n]^T$$

$$A = \begin{bmatrix} a_{11} & \dots & a_{1n} \\ \vdots & & \vdots \\ a_{m1} & \dots & a_{mn} \end{bmatrix} \in \mathbb{R}^{m \times n} \quad \max_{\text{p.p.}} \quad c^T x \quad Ax \leq b \quad x \geq 0$$

Vsak linearen program lahko zapišemo v standardni obliki.

Vse dele linearnega programa lahko preoblikujemo tako, da bodo v standardni obliki:

$$\begin{array}{l} \min f(x) \rightsquigarrow \max(-f(x)) \\ f(x) \geq b \rightsquigarrow -f(x) \leq -b \\ f(x) = b \rightsquigarrow f(x) \leq b \wedge f(x) \geq b \\ x_i \leq 0 \rightsquigarrow x_i = -x'_i \\ x_i \geq 0 \rightsquigarrow x_i = x'_i - x''_i \wedge x'_i, x''_i \geq 0 \end{array}$$

Grafično reševanje linearnih programov

Za linearne porgame z dvema spremenljivkama lahko narišemo območje, ki ga določajo pogoji. Nato izračunamo gradient kriterijske funkcije in premikamo v smeri gradienta proti točki, ki je v preseku polporostorov pogojev in čim dlje od izhodišča.

Simpleksna metoda

Linearni program zapišemo v standardni obliki. Če je kak $b_i < 0$, moramo uporabiti **dvofazno simpleksno metodo**, sicer nadaljujemo.

Linearni porgram zapišemo v *prvi* slovar.

$$\begin{array}{c} \overbrace{x_{n+1} = b_1 - a_{11}x_1 - \dots - a_{1n}x_n}^{1. \text{ slovar}} \\ \vdots \\ \overbrace{x_{n+m} = b_m - a_{m1}x_1 - \dots - a_{mn}x_n} \\ z = c_1x_1 + \dots + c_nx_n \end{array}$$

Vse spremenljivke x_1, \dots, x_{n+m} so nenegativne.

Spremenljivke na levi so **bazne**, na desni pa **nebazne**.

$$\begin{array}{lll} x_1, \dots, x_n & \dots & \text{prvotne spremenljivke} \\ x_{n+1}, \dots, x_{n+m} & \dots & \text{dopolnilne spremenljivke} \end{array}$$

Slovar je **dopusten**, če so vse konstante (čelni brez x) na desni nenegativne.

Če je slovar dopusten, ima *bazno* dopustno rešitev: vse *nebazne* spremenljivke so 0 in kriterijska funkcija je tedaj $z = 0$.

- Določimo:
 - vstopno spremenljivko**: izberem spremenljivko, ki ima v kriterijski funkciji pozitiven koeficient.
 - pivotno vrstico**: enakost, ki povečanje vstopne spremenljivke najbolj omejuje. Če ni omejena, je problem **neomejen** in končamo.
 - izstopno spremenljivko**: bazna spremenljivka v pivotni vrstici

- Iz pivotne vrstice izrazimo vstopno spremenljivko in pivotno vrstico zamenjamo z izražavo (vstopna spremenljivka gre v bazo na levo stran).
- V ostalih vrsticah in kriterijski funkciji vstopno spremenljivko nadomestimo z zgornjo izražavo.
- Dobimo naslednji slovar. Postopek ponavljamo dokler niso vsi koeficienti v kriterijski funkciji negativni ali enaki 0.

Iz zadnjega slovarja razberemo optimalne rešitve: spremenljivke, ki imajo v kriterijski funkciji negativen koeficient imajo vrednost 0, ostale pa lahko spreminjamo glede na omejitve.

Dvofazna simpleksna metoda

Če je $b \not\geq 0$, uporabimo dvofazno simpleksno metodo.

Prva faza

Konstruiramo pomožni problem. V vsaki neenakosti b_i prištejemo x_0 . Kriterijsko funkcijo pa spremenimo v $\max -x_0$.

Iz pomožnega problema zapišemo 1. slovar.

$$\begin{array}{c} x_{n+1} = b_1 + x_0 - a_{11}x_1 - \dots - a_{1n}x_n \\ \vdots \\ x_{n+m} = b_m + x_0 - a_{m1}x_1 - \dots - a_{mn}x_n \\ w = -x_0 \end{array}$$

Za vstopno spremenljivko izberemo x_0 za pivotno vrstico pa tisto v kateri je b_i najmanjši. Nato nadaljujemo z običajno simpleksno metodo.

Nadaljujemo z navadno simpleksno metodo in upoštevamo pravilo: x_0 ima prednost med kandidati za izstopno spremenljivko.

Če $w^* < 0$, prvotni problem ni dopusten, sicer nadlajujemo z drugo fazo.

Druga faza

Iz zadnjega slovarja pomežnega problem izbrisemo x_0 in kriterijsko funkcijo originalnega programa izrazimo z nebaznimi spremenljivkami. Nadaljujemo z običajno simpleksno metodo.

Dualnost pri linearnem programiranju

Vsak linearni program P ima dualno obliko P' :

$$\begin{array}{ll} \max & c^T x \\ \text{p.p.} & Ax \leq b \\ & x \geq 0 \end{array} \implies \begin{array}{ll} \min & b^T y \\ \text{p.p.} & A^T y \geq c \\ & y \geq 0 \end{array}$$

$$P'' = P$$

Šibki izrek o dualnosti - ŠID

x dopustna rešitev za P , y dopustna rešitev za $P' \implies$

$$c^T x \leq b^T y$$

x dopustna za P , y dopustna za P' in $c^T x = b^T y \implies$

x optimalna rešitev P , y optimalna rešitev P'

Krepki izrek o dualnosti - KID

x^* optimalna rešitev $P \implies$

$$\text{optimalna rešitev } P' \text{ in } c^T x^* = b^T y^*$$

Linearni program in njegov dual sta lahko:

	nedopusten	neomejen	optimalen
nedopusten	✓	✓	//KID
neomejen	✓	//ŠID	//ŠID, KID
optimalen	//KID	//ŠID, KID	✓

Dualno dopolnjevanje

Naj bo x dopustna za P in y dopustna za P' tedaj je:

x optimalna za P in y optimalna za $P' \iff$

$$\forall i = 1, \dots, m : \quad \sum_{j=1}^n a_{ij}x_j = b_i \quad \text{ali} \quad y_i = 0$$

$$\forall j = 1, \dots, n : \quad x_j = 0 \quad \text{ali} \quad \sum_{i=1}^m a_{ij}y_i = c_j$$

Ekvivalentno: x optimalna za P , y optimalna za $P' \iff$

$$\begin{array}{c} \sum_{j=1}^n a_{ij}x_j < b_i \implies y_i = 0 \quad \forall i \\ \text{in} \\ x_j > 0 \implies \sum_{i=1}^m a_{ij}y_i = c_j \quad \forall j \end{array}$$

Uporaba izreka o dualnem dopolnjevanju

Želimo dokazati, da je x^* optimalna rešitev linearnega programa P .

- Preverimo, da je x^* dopustna rešitev.
- Če je kakšna neenakost pri pogojih P izpolnjena s strogo neenakostjo, je pripadajoča dualna spremenljivka $y_i^* = 0$.
- Če je kaka $x_j^* > 0$, je pripadajoča dualna neenakost v P' izpolnjena z enakostjo:

$$\sum_{i=1}^n a_{ij}y_i = c_j$$

- Vzamemo enačbe iz 3. koraka in upoštevamo, da so nekateri y iz 2. koraka enaki 0. Rešimo dobljeni sistem (če ni rešljiv, x^* ni optimalna).
- Preverimo ali je dobljena rešitev y^* dopustna. Če je, sta x^* in y^* optimalni.

Dual splošnega problema

Splošna oblika linearnega programa je manj stroga standardna oblika. Dovolimo, da so pogoji postavljeni $z \leq$ lahko pa tudi $z =$. Poleg tega dovolimo, da nekatere spremenljivke niso omejene z $x_j \geq 0$.

Program v splošni obliki izgleda takole:

$$\begin{array}{ll} \max & \sum_{j=1}^n c_j x_j \\ \text{p.p.} & \sum_{j=1}^n a_{ij} x_i \leq b_i \quad \forall i = 1, \dots, m' \\ & \sum_{j=1}^n a_{ij} x_i = b_i \quad \forall i = m' + 1, \dots, m \\ & x_i \geq 0 \quad \forall i = 1, \dots, n' \end{array}$$

Njegov dual pa je:

$$\begin{array}{ll} \min & \sum_{i=1}^m b_i y_i \\ \text{p.p.} & \sum_{i=1}^{m'} a_{ij} y_i \leq c_j \quad \forall j = 1, \dots, n' \\ & \sum_{i=1}^m a_{ij} y_i = c_j \quad \forall j = n' + 1, \dots, n \\ & y_i \geq 0 \quad \forall i = 1, \dots, m' \end{array}$$

enakost $\overset{\text{dual}}{\iff}$ poljubna spremenljivka
neenakost $\overset{\text{dual}}{\iff}$ negativna spremenljivka

Dualno dopolnjevanje splošnega problema

x dopustna za P
 y dopustna za P'
 x optimalna za P in y optimalna za $P' \iff$

$$\forall i = 1, \dots, m' : \quad \sum_{j=1}^n a_{ij}x_j = b_i \quad \text{ali} \quad y_i = 0$$

$$\forall j = 1, \dots, n' : \quad x_j = 0 \quad \text{ali} \quad \sum_{i=1}^m a_{ij}y_i = c_j$$

Postopek reševanja

- Poiščemo začetno dopustno drevesno rešitev x z drevesom T
- Izračunamo ceno razvoza y za posamezna vozlišča
- Poiščemo vstopno povezavo $ij \notin T$, ki ustreza:
 - prazna: $x_{ij} = 0, y_i + c_{ij} < y_j \implies t = \min(\{x_e : e \text{ obratna}\} \cup \{u_e - x_e : e \text{ prema}\})$ na premih povečamo za t , na obratnih pomanjšamo za t
 - nasičena: $x_{ij} = u_{ij}, y_i + c_{ij} > y_j \implies t = \min(\{x_e : e \text{ prema}\} \cup \{u_e - x_e : e \text{ obratna}\})$ na premih pomanjšamo za t , na obratnih povečamo za t

Začetno dopustno drevesno rešitev poiščemo s pomožnim problemom:

Izberemo koren $r \in V$. Za vsako vozlišče v :

- $b_v < 0$ (proizvodnja): Če že obstaja povezava vr z kapaciteto $u_{vr} \geq -b_v$, nastavimo razvoz na tej povezavi na b_v , sicer dodamo povezavo vr z kapaciteto ∞ (dovolimo tudi več povezav med vozlišči).
- $b_v \geq 0$ (poraba): Če že obstaja povezava rv z kapaciteto $u_{rv} \geq b_v$, nastavimo razvoz na tej povezavi na $-b_v$, sicer dodamo povezavo rv z kapaciteto ∞ .

Umetne (dodane) povezav imajo ceno 1, prvotne pa 0. Prvotni problem je dopusten \iff vrednost pomožnega problema enaka 0.

Pretoki in prerezi

$G = (V, E)$... usmerjen graf
 $s, t \in V$... začetno in končno vozlišče
 $u_e \in [0, \infty)$... kapaciteta povezave

Iščemo pretok x_e , da veljajo Kirchoffovi zakoni in $0 \leq x_e \leq u_e$.

$$\sum_{\text{konec}(e)=v} x_e = \sum_{\text{začetek}(e)=v} x_e \quad \forall v \in V \setminus \{s, t\}$$

Radi bi *maksimizirali* pretok:

$$\sum_{\text{začetek}(e)=s} x_e = \sum_{\text{konec}(e)=t} x_e = v$$

Prevedba na problem razvoza

$b_v = 0 \quad \forall v \in V \qquad c_e = 0 \quad \forall e \in E$

u_e ostane nespremenjen

Dodamo povezavo ts z kapaciteto $u_{ts} = \infty$ in ceno $c_{ts} = -1$.

Povečujoča pot

Zaporedje $s = v_0, v_1, \dots, v_k = t$, da $\forall i = 1, \dots, k$ velja:

$$v_{i-1}v_i \in E, \quad x_{v_{i-1}v_i} < u_{v_{i-1}v_i}$$

ali

$$v_iv_{i-1} \in E, \quad x_{v_{i-1}v_i} > 0$$

Pretok na premih povezavah povečujoče poti povečamo za ε na obratnih pa pomanjšamo.

$$\varepsilon = \min\{x_e : e \text{ obratna}\} \cup \{u_e - x_e : e \text{ prema}\}$$

Prerez

Podmnožica $C \subseteq V$ je prerez, če velja $s \in C$ in $t \notin C$. Kapaciteta prereza je:

$$\sum_{\substack{i \in C \\ j \notin C}} u_{ij} \in [0, \infty)$$

Prostornina pretoka \leq kapaciteta prereza.

Če je prostornina pretoka = kapaciteti prerza, je pretok maksimalen in prerez minimalen.

Za problem pretoka velja natanko eno:

- neomejen*: kapaciteta vsakega prereza je ∞
- optimalen*: \exists prerez katerega kapaciteta je enaka maksimalnemu pretoku

Prirejanja in pokritja

Naj bo $G = (V, E)$ graf.

$M \subseteq E$ je **prirejanje**, če $\forall e, f \in M, e \neq f \implies e \cap f = \emptyset$
 $P \subseteq V$ je **pokritje**, če $\forall e \in E \exists v \in P : v \in E$

$\mu(G)$ = velikost največjega prirejanja
 $\tau(G)$ = velikost najmanjšega pokritja

M prirejanje, P pokritje $\implies |M| \leq |P|$

Če je $|M| = |P|$, je M največje prirejanje in P najmanjše pokritje in $\mu(G) = \tau(G) = |M| = |P|$.

Prirejanje je **maksimalno**, če ni vsebovano v nobenem večjem prirejanju.

V splošnem velja le $\mu(G) \leq \tau(G)$, za dvodelne grafe pa $\mu(G) = \tau(G)$.

$e \in E$ je **vezana**, če $e \in M$, sicer pa je **prosta**
 $v \in V$ je **vezano**, če $\exists e \in M : v \in e$, sicer pa je **prosto**

Alternirajoča pot je pot na kateri se izmenjujejo proste in vezane povezave.

Povečujoča pot je alternirajoča pot, ki se začen in konča v prostem vozlišču.

Če na povečujoči poti zamenjamo proste in vezane povezave, dobimo za 1 večje prirejanje.

M je največje prirejanje \iff ne obstaja povečujoča pot.

Madžarska metoda

$G = (V, E)$ dvodelni graf, $V = X \cup Y$, M prirejanje

$S = \{\text{prosta vozlišča v } X\} \quad T = \emptyset$

Vsak korak:

$$S' = S \cup \left\{ \begin{array}{l} \text{vozlišča v } X, \text{ do katerih lahko iz } T \\ \text{pridemo po vezanih povezavah} \end{array} \right\}$$
$$T' = T \cup \left\{ \begin{array}{l} \text{vozlišča v } Y, \text{ do katerih lahko iz } S \\ \text{pridemo po prostih povezavah} \end{array} \right\}$$

Če T vsebuje prosto vozlišče, imamo povečujočo pot, ki jo uporabimo za povečanje prirejanja.

Sicer pa pridemo do koraka kjer je $T' = T$ in $S' = S$. V tem primeru je M največje prirejanje.

Hallov izrek

$G = (V, E)$ dvodelni graf, $V = X \cup Y$

\exists popolno prirejanje iz X v $Y \iff \forall A \subseteq X : |A| \leq |N(A)|$

Madžarska metoda z utežmi

Imamo plon graf $K_{n,n}$; povezava med x_i in y_j ima utež c_{ij}

$$c = [c_{ij}] \in \mathbb{R}^{n \times n}$$

Popolno prirejanje je podano z $\pi \in S_n$: $x_i \sim y_{\pi(i)}$.

Iščemo prirejanje z najmanjšo utežjo:

$$\min_{\pi \in S_n} \sum_{i=1}^n c_{i\pi(i)}$$

Interpretacija: Razporeditev n opravi n ljudem.

Madžarska metoda - postopek

- Od vsake vrstice odštejemo njen minimum.
Od vsakega stolpca odštejemo njegov minimum. *V vsaki vrstici in stolpcu je vsaj ena ničla*
- Pokrijemo vse ničle v matriki pokrijemo z manj kot n vrsticami in stolpci.

ε := najmanjše nepokrito polje > 0

- $2 \times$ pokritim poljem prištejemo ε
- nepokritim pa odštejemo ε

- Če ne najdemo takih vrstic in stolpcev, lahko najdemo n ničel v različnih vrsticah in stolpcih. To nam daje minimalno popolno prirejanje.

Iskanje najkrajše poti

Pregled v širino (BFS) $O(|V| + |E|)$

vhod: neutezen, neusmerjen graf G , zacetno vozlisce r
izhod: razdalje med vozliscem r in ostalimi
 $Q \leftarrow r$
 $d(r) \leftarrow 0$
 $\pi(r) \leftarrow \text{NULL}$
obiskan(r) \leftarrow NE
za **vsak** $v \in V \setminus \{r\}$:
 $d(v) \leftarrow \infty$
 $\pi(v) \leftarrow \text{NULL}$
 obiskan(v) \leftarrow NE
dokler $Q \neq \emptyset$:
 $v \in Q$
 $Q \leftarrow Q \setminus v$
 obiskan(v) \leftarrow JA
 za **vsak** $u \in N(v)$:
 ce obiskan(u) = NE:
 $d(u) \leftarrow d(v) + 1$
 $\pi(u) = v$
 $Q \leftarrow Q \cup \{u\}$
vrni d, π

Dijkstrov algoritem

vhod: usmerjen, utezen ($w_e \geq 0$) graf $G = (V, E)$, koren r
izhod: razdalje med vozliscem r in ostalimi
 $d(r) \leftarrow 0$
 $\pi(r) \leftarrow \text{NULL}$
za **vsak** $v \in V \setminus \{r\}$:
 $d(v) \leftarrow \infty$
 $\pi(v) \leftarrow \text{NULL}$
 $Q \leftarrow V$
dokler $Q \neq \emptyset$:
 $v \leftarrow$ element Q z min d
 $Q \leftarrow Q \setminus v$
 ce $d(v) = \infty$:
 konec

sicer:
 za **vsak** $u \in N(v) \cap Q$:
 ce $d(u) > d(v) + w_{vu}$:
 $d(u) \leftarrow d(v) + w_{vu}$
 $\pi(u) \leftarrow v$
vrni d, π

Aciklični graf

vhod: utezen, usmerjen graf $G = (V, E)$ brez ciklov
izhod: topoloska urejenost φ
za **vsak** $v \in V$:
 $\text{st}(v) \leftarrow \deg^+(v)$
 $i \leftarrow 1$
dokler $\exists v \in V : \text{st}(v) = 0$:
 $\varphi(v) \leftarrow i$
 za **vse** $vu \in E$:
 $\text{st}(u) \leftarrow \text{st}(u) - 1$
 $i \leftarrow i + 1$
ce $i \leq |V|$:
 vrni FALSE
sicer:
 vrni φ

vhod: topoloska urejenost φ , koren r
izhod: razdalje med vozliscem r in ostalimi
 $d(r) \leftarrow 0$
 $\pi(r) \leftarrow \text{NULL}$
za **vsak** $v \in V \setminus \{r\}$:
 $d(v) \leftarrow \infty$
 $\pi(v) \leftarrow \text{NULL}$
 $i \leftarrow \varphi(r)$
za **vsak** $j \in \{i, i + 1, \dots, |V|\}$:
 $v \leftarrow \varphi^{-1}(j)$
 za **vsak** $vu \in E$:
 ce $d(u) = d(v) + w_{ue}$:
 $d(u) \leftarrow d(v) + w_{vu}$
 $\pi(u) \leftarrow v$
vrni d, π

Bellman-Ford

Floyd-Warshellov algoritem

Konveksna optimizacija

Afine množice

Množica $A \subseteq \mathbb{R}^n$, $A \neq \emptyset$ je **afina**, če velja:

$\forall x, y \in A \quad \forall \lambda \in \mathbb{R} : (1 - \lambda)x + \lambda y \in A$

Premica med dvema poljubnima točkama iz A mora biti vsebovana v A.
Afina kombinacija:

$\alpha_1x_1 + \dots + \alpha_nx_n \qquad \alpha_1 + \dots + \alpha_n = 1$

Naslednje trditve so ekvivalentne:

- A je afina
- vsaka afina kombinacija vektorjev iz A je v A
- $A = V + a = \{v + a \mid v \in V\}$
za nek $V \in \mathbb{R}^n$ linearen podprostor in $a \in \mathbb{R}^n$

Konveksne množice

Množica *A* ⊆ ℝ^{*n*} je **konveksna**, če velja:

∀*x*, *y* ∈ *A* ∀λ ∈ [0, 1] : (1 − λ)*x* + λ*y* ∈ *A*

Daljica med dvema poljibnima točkama iz A mora biti vsebovana v A.

Množica **ni** konveksna, če

∃*x*, *y* ∈ *A* ∃λ ∈ [0, 1] : (1 − λ)*x* + λ*y* ∉ *A*

Naj bo Ω^{konv} ⊆ ℝ^{*n*} in *g_i* : Ω → ℝ konv. fun.
Tedad je *D* = {*x* ∈ Ω | *g_i*(*x*) ≤ 0 ∀*i*} **konveksna**.

Konveksna kombinacija:

α₁*x*₁ + ⋯ + α_{*n*}*x*_{*n*}
α₁ + ⋯ + α_{*n*} = 1 α₁ + ⋯ + α_{*n*} ≥ 0

Afin podprostor (= zaprt za afine kokbinacije = premaknjen linearen prostor) je *konveksen*.

Presek konveksnih množic *A_i*, ∀*i* ∈ *I* je konveksen.

Unija koknveksnih množic pa ni nujno konveksna.

A konveksna ⇔ poljubna konveksna kombinacija vektorjev iz *A* v *A*.

Konveksna ogrinjača:

Conv
(
A
)
=

C

(
A
)
=

⋂

K

K
konv.
A
⊆
K

{\displaystyle \;{\mathrm {Conv} (A)}={\mathcal {C}}(A)={\bigcap \limits _{A\subseteq K}K^{\mathrm {konv} }}\;\;{\mathrm {Conv} (A)}=\left\{\sum _{i=1}^{k}\lambda _{i}x_{i}\;\left| \;k\in \mathbb {N} ,\;\lambda _{i}\geq 0,\;\sum _{i=1}^{k}\lambda _{i}=1,\;\;x_{i}\in A\right.\right\}}

- A* ⊆ Conv(*A*)
- Conv(*A*) je konveksna
- A* konveksna ⇒ Conv(*A*) = *A*
- A* ⊆ *B*, *B* konveksna ⇒ Conv(*A*) ⊆ *B*
- Conv(*A*) = {konveksna kombinacija vektorjev iz *A*}

Ekstremna točka: *a* ∈ *A*^{konv} je ekstremna, če
∀*x*, *y* ∈ *A*, *x*, *y* ≠ *a* : ∄λ ∈ [0, 1] : *a* = (1 − λ)*x* + λ*y*
Točka ni ekstremna, če laži v notranjosti kake daljice med točkama iz A.

Ekstremne točke vedno ležijo na robu. Robne toče pa niso nujno ekstremne.

Konveksni stožci

A ⊆ ℝ^{*n*} je konveksni stožec, če

∀*x*, *y* ∈ *A* ∀λ, μ ≥ 0 : λ*x* + μ*y* ∈ *A*

Konveksni stožec, je konveksna množica, ni pa nujno obratno.

Vsak linearni podprostor je konveksen stožec.

Konveksni stožec napet na *a*₁, . . . , *a_n* ∈ ℝ^{*n*}:
S(*a*₁, . . . , *a_n*) = {λ₁*a*₁ + ⋯ + λ_{*n*}*a_n* | λ₁, . . . , λ_{*n*} ≥ 0}

Dualni stožec množice *A* ⊆ ℝ^{*n*}:

A^{*} = {*x* ∈ ℝ^{*n*} : *x*^{*T*} *a* ≥ 0 ∀*a* ∈ *A*}

V A^{} so vektorji, ki z vsemi vektorji iz A tvorijo ostri kot.*

A
⊆

A

∗∗

{\displaystyle \;A\subseteq A^{**}}

Farkaševa lema

Geometrijska oblika:

S^{****}(*a*₁, . . . , *a_n*) = *S*(*a*₁, . . . , *a_n*)

Algebraična oblika:

Prva varianta:

∃*x* ≥ 0 : *Ax* = *b* ⇔ ∀*y* : *A*^{*T*} *y* ≥ 0 ⇒ *b*^{*T*} *y* ≥ 0

b ∈ *S*(*a*₁, . . . , *a_n*) ⇔ *b* ∈ *S*^{****}(*a*₁, . . . , *a_n*)

Druga varianta:

∃*x* ≥ 0 : *Ax* ≤ *b* ⇔ ∀*y* ≥ 0 : *A*^{*T*} *y* ≥ 0 ⇒ *b*^{*T*} *y* ≥ 0

Konveksne funkcije

Naj bo *K*^{konv} ⊆ ℝ^{*n*}; funkcija *f* : *K* → ℝ je konveksna, če
∀*x*, *y* ∈ *K* ∀λ ∈ [0, 1] :

f((1 − λ)*x* + λ*y*) ≤ (1 − λ)*f*(*x*) + λ*f*(*y*)

Funkcija je konveksna, če je definirana na konveksnem območju in graf vedno leži pod zveznico dveh točk na grafu.

Če zgoraj velja stroga neenakost, je funkcija **strogo konveksna**.

f strogo konveksna ⇔ *H_f* > 0.

Če ima strogo konveksna funkcija maksimum, je v *ekstremni točki*.

Konkavne funkcije

Naj bo *K*^{konv} ⊆ ℝ^{*n*}; funkcija *f* : *K* → ℝ je konkavna, če

∀*x*, *y* ∈ *K* ∀λ ∈ [0, 1] :

f((1 − λ)*x* + λ*y*) ≥ (1 − λ)*f*(*x*) + λ*f*(*y*)

Če je *f* konveksna, je −*f* konkavna.

Funkcija *f* je **afina** ⇔ konveksna in konkavna

- f* : *K* → ℝ, *c* ≥ 0, *f* konveksna ⇒ *c* · *f* konveksna
- f*, *g* : *K* → ℝ, *f*, *g* konveksni ⇒ *f* + *g* konveksna
- g* : *K* → ℝ^{*n*} afina ⇒ *g*(*K*) konveksna
- f* : *g*(*K*) → ℝ konveksna ⇒ *f* ◦ *g* konveksna
- g* : *K* → ℝ, *f* : Conv(*g*(*K*)) → ℝ, *f*, *g* konveksni
- f* naraščujoča ⇒ *f* ◦ *g* konveksna

Konveksne funkcije in optimizacija

Naj bo *A* ⊆ ℝ^{*n*} in *f* : *A* → ℝ.

- f* ima v *x* ∈ *A* **globalni maksimum**, če

∀

x
′
∈
A
:

f
(

x
′
)
≥
f
(

x
′
)

{\displaystyle \;\;\;\forall x'\in A:\;f(x')\geq f(x')}
- f* ima v *x* ∈ *A* **lokalni maksimum**, če

∃
ε
>
0
:

∀

x
′
∈
A
∩

K

ε

(
x
)
:

f
(
x
)
≥
f
(

x
′
)

{\displaystyle \;\;\;\exists \varepsilon >0:\;\;\forall x'\in A\cap K_{\varepsilon }(x):\;f(x)\geq f(x')}

Če je *x* lokalni minimum konveksne funkcije, je tudi globalni minimum.

Preverjanje konveksnosti funkcije

S prvim odvodom

f : *K*^{konv}, odp → ℝ odvedljiva

f konveksna ⇔ *f*(*y*) ≥ *f*(*x*) + (∇*f*(*x*))^{*T*} (*y* − *x*)

Z drugim odvodom

f : Ω^{odp} ⊆ ℝ^{*n*} → ℝ dvakrat zvezno odvedljiva

Hessejeva matrika:

H

f

=
⌊

∂

2

f

∂

x

i

∂

x

j

⌋

n

i
,
j
=
1

{\displaystyle H_{f}=\left[{\frac {\partial ^{2}f}{\partial x_{i}\partial x_{j}}}\right]_{i,j=1}^{n}}

f konveksna ⇔ *H_f* ≥ 0

f : Ω → ℝ konveksna ⇔ *h_{x,y}* : *I_{x,y}* → ℝ,
h_{x,y}(λ) = *f*(*x* + λ*y*), konveksna za ∀*x* ∈ ℝ ∀*y* ∈ ℝ^{*n*}
I_{x,y} = {λ ∈ ℝ : *x* + λ*y* ∈ Ω}

Lastne vrednosti matrike *A* so ničle karakterističnega polinoma *det*(*A* − λ*I*).

Lastni podprostor vrednosti λ je Ker(*A* − λ*I*) \ {0}.

A ∈ ℝ^{*n* × *n*} je **diagonalizabilna**, če ima *n* linearno neodvisnih lastnih vektorjev.
Tedad je *A* = *PDP*^{−1}, kjer je *D* diagonalna z lastnimi vrednostmi na diagonali, *P* pa obrnljiva z lastnimi vektorji v stolpcih.

Če je *A* **simetrična** (*A*^{*T*} = *A*), so vse lastne vrednosti realne in *A* je diagonalizabilna v ortonormirani bazi (lastni vektorji različnih lastnih vrednosti so ⊥).

Matrika *A* je **pozitivno semidefinitna** (*A* ≥ 0)
⇔ vse lastne vrednosti λ ≥ 0
⇔ *x*^{*T*} *Ax* = ∑_{*i*,*j*=1}^{*n*} *a_{ij}* *x_i* *x_j* ≥ 0
⇔ vse glavne poddeterminante ≥ 0
Glavne poddeterminante dobimo tako, da izbiršemo nekatere vrstice in stolpce z enakimi indeksi.

Matrika *A* =

⌊

a

b

c

d

⌋

{\displaystyle \;\;{\begin{bmatrix}a&b\\c&d\end{bmatrix}}}

 je *A* ≥ 0 ⇔ *ac* − *b*² ≥ 0 in *a* ≥ 0

Konveksne funkcije in vezani ekstreми

Ω ⊆ ℝ odprta
f, *g*₁, . . . , *g_m* : Ω → ℝ zvezno odvedljive
D = {*x* ∈ Ω : *g_i*(*x*) ≤ 0 ∀*i* = 1, . . . , *m*}

min
p
.
p
.

f
(
x
)

x
∈

Ω

o
d
p
⊆

R

n

g

1

(
x
)
≤
0

⋮

g

m

(
x
)
≤
0

{\displaystyle \;\;\;\min _{p.p.}{f(x)}_{x\in \Omega ^{odp}\subseteq \mathbb {R} ^{n}}g_{1}(x)\leq 0\;\;\;\vdots \;\;\;g_{m}(x)\leq 0}

Karush–Kuhn–Tuckerjevi pogoji

Lagrangeeva funkcija

L(*x*, λ) = *f*(*x*) + ∑_{*j*=1}^{*m*} λ_{*j*} *g_j*(*x*)

x^{*} ∈ Ω zadošča pogojem KKT, če ∃λ₁, . . . , λ_{*m*} ≥ 0, da velja:

Lx_i (*x*^{*}) = 0 ∇*i* = 1, . . . , *n*

λ_{*j*} *g_j* (*x*^{*}) = 0 ∇*j* = 1, . . . , *m*

g_j (*x*^{*}) ≤ 0 ∇*j* = 1, . . . , *m*

V splošnem KKT pogoji niso ne potrebni ne zadostni za globalni/lokalni ekstrem.

Potrebnost pogojev KKT optimalnost:
Če ima *f* v točki *x*^{*} ∈ *D* lokalni min na *D* in so vezi v *x*^{*} regularne, točka *x*^{*} zadošča pogojem KKT.

Zadostni pogoji za regularnost vezi:
Če velja vsaj en od pogojev so vezi v *x*^{*} regularne.

- g*₁, . . . , *g_m* afine
- Ω konveksna, *f*, *g*₁, . . . , *g_m* konveksne in notranjost *D*^o ≠ ∅
- vse množice vektorjev {∇*g_i*(*x*^{*}) | *g_i*(*x*^{*}) = 0} linearno neodvisne

Zadostnost pogojev KKT za optimalnost:
Ω odprta, konveksna množica, *f*, *g*₁, . . . , *g_m* : Ω → ℝ konveksne in odvedljive
Če *x*^{*} ustreza KKT pogojem, je globalni minimum.

Za konveksni problem z *D*^o ≠ ∅ so KKT pogoji ⇔ *x*^{*} globalni minimum.

Celoštevilski linearni programi

max
p
.
p
.

c

T

x

A
x
≤
b

x
≥
0

x
∈

Z

{\displaystyle \;\;\;\max _{p.p.}{c^{T}x}_{Ax\leq b\;\;\;x\geq 0\;\;\;x\in \mathbb {Z} }

Če želimo, da je δ = 1 natanko tedaj ko je *x* > 0, dodamo pogoj:

x
M

≥
δ
≥
M
x

δ
∈
{
0
,
1
}

{\displaystyle {\frac {x}{M}}\geq \delta \geq Mx\;\;\;\delta \in \{0,1\}}

Kjer je *M* neko dovoj veliko število, da je vedno

x
M

≤
1
.

Za δ_{*i*} ∈ {0, 1} se logični izrazi lahko pretvorijo v pogoje:

δ₁ = 1 ∨ δ₂ = 1 ⇔ δ₁ + δ₂ ≥ 1
δ₁ = 1 ∧ δ₂ = 1 ⇔ δ₁ ≥ 1, δ₂ ≥ 1
δ₁ = 1 ⇒ δ₂ = 1 ⇔ 1 − δ₁ + δ₂ ≥ 1, δ₂ ≥ δ₁