

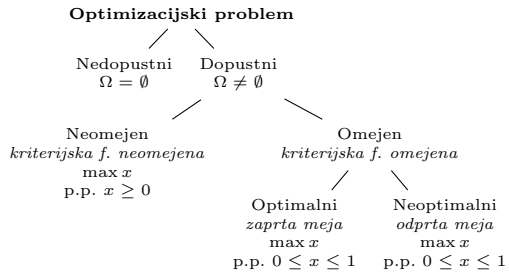
Optimizacijske naloge

Optimizacijska naloga je $(\Omega, f, \max/\min/\sup/\inf,)$ kjer je:

- Ω množica dopustnih rešitev
- $f : \Omega \rightarrow \mathbb{R}$ kriterijska funkcija

$x^* \in \Omega$ je *optimalna* rešitev problema (Ω, f, \max) , če velja

$$\forall x \in \Omega : f(x) \leq f(x^*)$$



Linearno programiranje

$(\Omega, f, \min/\max)$ je linearni porgram, če je Ω podana z linearnimi enakostmi in neenakostmi (\leq, \geq) in je f linearna.

Standardna oblika linearnega pograma

Linearni porgram je v *standardni* obliki, če iščemo \max in so vsi pogoji neenakosti \leq in so vse spremenljivke nenegativne.

$$\begin{array}{ll} \max & c_1x_1 + \dots + c_nx_n \\ \text{p.p.} & a_{11}x_1 + \dots + a_{1n}x_n \leq b_1 \\ & \vdots \\ & a_{m1}x_1 + \dots + a_{mn}x_n \leq b_m \\ & x_1, \dots, x_n \geq 0 \end{array}$$

To lahko zapišemo v matrični obliki:

$$c = [c_1 \dots c_n]^T \quad b = [b_1 \dots b_m]^T \quad x = [x_1 \dots x_n]^T$$

$$A = \begin{bmatrix} a_{11} & \dots & a_{1n} \\ \vdots & & \vdots \\ a_{m1} & \dots & a_{mn} \end{bmatrix} \in \mathbb{R}^{m \times n} \quad \begin{array}{ll} \max & c^T x \\ \text{p.p.} & Ax \leq b \\ & x \geq 0 \end{array}$$

Vsak linearen program lahko zapišemo v standardni obliki.

Vse dele linearnega programa lahko preoblikujemo tako, da bodo v standardni obliki:

$$\begin{array}{ll} \min f(x) \rightsquigarrow \max(-f(x)) \\ f(x) \geq b \rightsquigarrow -f(x) \leq -b \\ f(x) = b \rightsquigarrow f(x) \leq b \wedge f(x) \geq b \\ x_i \leq 0 \rightsquigarrow x_i = -x'_i \\ x_i \geq 0 \rightsquigarrow x_i = x'_i - x''_i \wedge x'_i, x''_i \geq 0 \end{array}$$

Grafično reševanje linearnih programov

Za linearne porgame z dvema spremenljivkama lahko narišemo območje, ki ga določajo pogoji. Nato izračunamo gradient kriterijske funkcije in premikamo v smeri gradienta proti točki, ki je v preseku polporostorov pogojev in čim dlje od izhodišča.

Simpleksna metoda

Linearni program zapišemo v standardni obliki. Če je kak $b_i < 0$, moramo uporabiti **dvofazno simpleksno metodo**, sicer nadaljujemo.

Linearni porgram zapišemo v *prvi* slovar.

$$\begin{array}{c} \overbrace{x_{n+1} = b_1 - a_{11}x_1 - \dots - a_{1n}x_n}^{1. \text{ slovar}} \\ \vdots \\ \hline x_{n+m} = b_m - a_{m1}x_1 - \dots - a_{mn}x_n \\ z = c_1x_1 + \dots + c_nx_n \end{array}$$

Vse spremenljivke x_1, \dots, x_{n+m} so nenegativne.

Spremenljivke na levi so **bazne**, na desni pa **nebazne**.

$$\begin{array}{lll} x_1, \dots, x_n & \dots & \text{prvotne spremenljivke} \\ x_{n+1}, \dots, x_{n+m} & \dots & \text{dopolnilne spremenljivke} \end{array}$$

Slovar je **dopusten**, če so vse konstante (čelni brez x) na desni nenegativne.

Če je slovar dopusten, ima *bazno* dopustno rešitev: vse *nebazne* spremenljivke so 0 in kriterijska funkcija je tedaj $z = 0$.

- Določimo:
 - vstopno spremenljivko**: izberem spremenljivko, ki ima v kriterijski funkciji pozitiven koeficient.
 - pivotno vrstico**: enakost, ki povečanje vstopne spremenljivke najbolj omejuje. Če ni omejena, je problem **neomejen** in končamo.
 - izstopno spremenljivko**: bazna spremenljivka v pivotni vrstici
- Iz pivotne vrstice izrazimo vstopno spremenljivko in pivotno vrstico zamenjamo z izražavo (vstopna spremenljivka gre v bazo na levo stran).
- V ostalih vrsticah in kriterijski funkciji vstopno spremenljivko nadomestimo z zgornjo izražavo.
- Dobimo naslednji slovar. Postopek ponavljamo dokler niso vsi koeficienti v kriterijski funkciji negativni ali enaki 0.

Iz zadnjega slovarja razberemo optimalne rešitve: spremenljivke, ki imajo v kriterijski funkciji negativen koeficient imajo vrednost 0, ostale pa lahko spreminjamo glede na omejitve.

Dvofazna simpleksna metoda

Če je $b \not\geq 0$, uporabimo dvofazno simpleksno metodo.

Prva faza

Konstruiramo pomožni problem. V vsaki neenakosti b_i prištejemo x_0 . Kriterijsko funkcijo pa spremenimo v $\max -x_0$.

Iz pomožnega problema zapišemo 1. slovar.

$$\begin{array}{c} x_{n+1} = b_1 + x_0 - a_{11}x_1 - \dots - a_{1n}x_n \\ \vdots \\ \hline x_{n+m} = b_m + x_0 - a_{m1}x_1 - \dots - a_{mn}x_n \\ w = -x_0 \end{array}$$

Za vstopno spremenljivko izberemo x_0 za pivotno vrstico pa tisto v kateri je b_i najmanjši. Nato nadaljujemo z običajno simpleksno metodo.

Nadaljujemo z navadno simpleksno metodo in upoštevamo pravilo: x_0 ima prednost med kandidati za izstopno spremenljivko.

Če $w^* < 0$, prvotni problem ni dopusten, sicer nadlajujemo z drugo fazo.

Druga faza

Iz zadnjega slovarja pomežnega problem izberimo x_0 in kriterijsko funkcijo originalnega programa izrazimo z nebaznimi spremenljivkami. Nadaljujemo z običajno simpleksno metodo.

Dualnost pri linearnem programiranju

Vsak linearni program P ima dualno obliko P' :

$$\begin{array}{lll} \max & c^T x & \\ \text{p.p.} & Ax \leq b \\ & x \geq 0 \end{array} \implies \begin{array}{lll} \min & b^T y & \\ \text{p.p.} & A^T y \geq c \\ & y \geq 0 \end{array}$$
$$P'' = P$$

Šibki izrek o dualnosti - ŠID

x dopustna rešitev za P , y dopustna rešitev za $P' \implies$

$$c^T x \leq b^T y$$

x dopustna za P , y dopustna za P' in $c^T x = b^T y \implies$

x optimalna rešitev P , y optimalna rešitev P'

Krepki izrek o dualnosti - KID

x^* optimalna rešitev $P \implies$

optimalna rešitev P' in $c^T x^* = b^T y^*$

Linearni program in njegov dual sta lahko:

	nedopusten	neomejen	optimalen
nedopusten	✓	✓	//KID
neomejen	✓	//ŠID	//ŠID, KID
optimalen	//KID	//ŠID, KID	✓

Dualno dopolnjevanje

Naj bo x dopustna za P in y dopustna za P' tedaj je:

x optimalna za P in y optimalna za $P' \iff$

$$\forall i = 1, \dots, m : \quad \sum_{j=1}^n a_{ij}x_j = b_i \quad \text{ali} \quad y_i = 0$$

$$\forall j = 1, \dots, n : \quad x_j = 0 \quad \text{ali} \quad \sum_{i=1}^m a_{ij}y_i = c_j$$

Ekvivalentno: x optimalna za P , y optimalna za $P' \Leftrightarrow$

$$\sum_{j=1}^n a_{ij}x_j < b_i \implies y_i = 0 \quad \forall i$$

in

$$x_j > 0 \implies \sum_{i=1}^m a_{ij}y_i = c_j \quad \forall j$$

Uporaba izreka o dualnem dopolnjevanju

Želimo dokazati, da je x^* optimalna rešitev linearnega programa P .

- Preverimo, da je x^* dopustna rešitev.
- Če je kakšna neenakost pri pogojih P izpolnjena s strogo neenakostjo, je pripadajoča dualna spremenljivka $y_i^* = 0$.

- Če je kaka $x_j^* > 0$, je pripadajoča dualna neenakost v P' izpolnjena z enakostjo:

$$\sum_{i=1}^n a_{ij}y_i = c_j$$

- Vzamemo enačbe iz 3. koraka in upoštevamo, da so nekateri y iz 2. koraka enaki 0. Rešimo dobljeni sistem (če ni rešljiv, x^* ni optimalna).
- Preverimo ali je dobljena rešitev y^* dopustna. Če je, sta x^* in y^* optimalni.

Dual splošnega problema

Splošna oblika linearnega programa je manj stroga standardna oblika. Dovolimo, da so pogoji postavljeni $z \leq$ lahko pa tudi $z =$. Poleg tega dovolimo, da nekatere spremenljivke niso omejene z $x_j \geq 0$.

Program v splošni obliki izgleda takole:

$$\begin{array}{lll} \max & \sum_{j=1}^n c_j x_j & \\ \text{p.p.} & \sum_{j=1}^n a_{ij} x_i \leq b_i & \forall i = 1, \dots, m' \\ & \sum_{j=1}^n a_{ij} x_i = b_i & \forall i = m' + 1, \dots, m \\ & x_i \geq 0 & \forall i = 1, \dots, n' \end{array}$$

Njegov dual pa je:

$$\begin{array}{lll} \min & \sum_{i=1}^m b_i y_i & \\ \text{p.p.} & \sum_{i=1}^m a_{ij} y_i \leq c_j & \forall j = 1, \dots, n' \\ & \sum_{i=1}^m a_{ij} y_i = c_j & \forall j = n' + 1, \dots, n \\ & y_i \geq 0 & \forall i = 1, \dots, m' \end{array}$$

$$\begin{array}{ll} \text{enakost} \xleftrightarrow{\text{dual}} \text{poljubna spremenljivka} \\ \text{neenakost} \xleftrightarrow{\text{dual}} \text{nenegativna spremenljivka} \end{array}$$

Dualno dopolnjevanje splošnega problema

x dopustna za P
 y dopustna za P'
 x optimalna za P in y optimalna za $P' \Leftrightarrow$

$$\begin{array}{lll} \forall i = 1, \dots, m' : & \sum_{j=1}^n a_{ij}x_j = b_i & \text{ali} \quad y_i = 0 \\ \forall j = 1, \dots, n' : & x_j = 0 & \text{ali} \quad \sum_{i=1}^m a_{ij}y_i = c_j \end{array}$$

Ekonomski pomen dualnih spremenljivk

Naj bo P linearni program, \exists neizrojena optimalna rešitev (v zadnjem slovarju so vse konstante > 0). Potem $\exists \varepsilon > 0$, da velja

$$\Delta z^* = \sum_{i=1}^m y_i^* \Delta b_i$$

kjer je y^* optimalna rešitev duala, Δz^* sprememba optimalne vrednosti, Δb_i pa sprememba dense strani pogojev in $|\Delta b_i| < \varepsilon$.

Torej če desni strani pogojev v P prištejemo dovolj majhen Δb , se optimalna vrednost z^* programa P spremeni za $\Delta z^* = \Delta b^T y^*$.

y^* nam tedaj da "tržno ceno" dobrin. Če želimo povečati dobrino b_i , se nam dobiček poveča za $b_i y_i^*$. Torej za enoto dobrine i ne smemo plačati več kot y_i^* .

Umetne (dodane) povezav imajo ceno 1, prvotne pa 0.
Prvotni problem je dopusten \iff vrednost pomožnega problema enaka 0.

$$A \subseteq A^{**}$$

Farkaševa lema

Geometrijska oblika:

$$S^{**}(a_1,\ldots,a_n)=S(a_1,\ldots,a_n)$$

Algebraična oblika:

Prva varianta:

$$\exists x \geq 0: Ax=b \iff \forall y: A^Ty \geq 0 \implies b^Ty \geq 0$$

$$b \in S(a_1,\ldots,a_n) \iff b \in S^{**}(a_1,\ldots,a_n)$$

Druga varianta:

$$\exists x \geq 0: Ax \leq b \iff \forall y \geq 0: A^Ty \geq 0 \implies b^Ty \geq 0$$

Konveksne funkcije

Naj bo *K*^{konv} ⊆ ℝⁿ; funkcija *f* : *K* → ℝ je konveksna, če

$$\forall x,y \in K \, \forall \lambda \in [0,1]: \\ f((1-\lambda)x+\lambda y) \leq (1-\lambda)f(x)+\lambda f(y)$$

Funkcija je konveksna, če je definirana na konveksnem območju in graf vedno leži pod zveznico dveh točk na grafu.

Če zgoraj velja stroga neenakost, je funkcija **strogo konveksna**.

f strogo konveksna ⟺ *H*_{*f*} > 0.

Če ima strogo konveksna funkcija maksimum, je v *ekstremni točki*.

Konkavne funkcije

Naj bo *K*^{konv} ⊆ ℝⁿ; funkcija *f* : *K* → ℝ je konkavna, če

$$\forall x,y \in K \, \forall \lambda \in [0,1]: \\ f((1-\lambda)x+\lambda y) \geq (1-\lambda)f(x)+\lambda f(y)$$

Če je *f* konveksna, je −*f* konkavna.

Funkcija *f* je **afina** ⟺ konveksna in konkavna

- f* : *K* → ℝ, *c* ≥ 0, *f* konveksna ⟹ *c* · *f* konveksna
- f, g* : *K* → ℝ, *f, g* konveksni ⟹ *f* + *g* konveksna
- g* : *K* → ℝⁿ afina ⟹ *g*(*K*) konveksna
- f* : *g*(*K*) → ℝ konveksna ⟹ *f* o *g* konveksna
- g* : *K* → ℝ, *f* : Conv(*g*(*K*)) → ℝ, *f, g* konveksni
- f* naraščujoča ⟹ *f* o *g* konveksna

Konveksne funkcije in optimizacija

Naj bo *A* ⊆ ℝⁿ in *f* : *A* → ℝ.

- f* ima v *x* ∈ *A* **globalni maksimum**, če

$$\forall x' \in A: \; f(x) \geq f(x')$$

- f* ima v *x* ∈ *A* **lokalni maksimum**, če

$$\exists \varepsilon > 0: \; \forall x' \in A \cap K_\varepsilon(x): \; f(x) \geq f(x')$$

Če je *x* lokalni minimum konveksne funkcije, je tudi globalni minimum.

Preverjanje konveksnosti funkcije

S prvim odvodom

f : *K*^{konv}, odp → ℝ odvedljiva

$$f \; \text{konveksna} \iff f(y) \geq f(x) + (\nabla f(x))^T (y-x)$$

Z drugim odvodom

f : Ω^{odp} ⊆ ℝⁿ → ℝ dvakrat zvezno odvedljiva

Hessejeva matrika:

$$H_f=\left[\frac{\partial^2 f}{\partial x_i \partial x_j}\right]_{i,j=1}^n$$

$$f \; \text{konveksna} \iff H_f \geq 0$$

f : Ω → ℝ konveksna ⟺ *h*_{*x,y*} : *I*_{*x,y*} → ℝ, *h*_{*x,y*}(λ) = *f*(*x* + λ*y*), konveksna za ∀*x* ∈ ℝ ∀*y* ∈ ℝⁿ
*I*_{*x,y*} = {λ ∈ ℝ : *x* + λ*y* ∈ Ω}

Lastne vrednosti matrike *A* so ničle karakterističnega polinoma *det*(*A* − λ*I*).

Lastni podprostor vrednosti λ je Ker(*A* − λ*I*) \ {0}.

A ∈ ℝ^{*n* × *n*} je **diagonalizabilna**, če ima *n* linearno neodvisnih lastnih vektorjev. Tedad je *A* = *PDP*^{−1}, kjer je *D* diagonalna z lastnimi vrednostmi na diagonali, *P* pa obrnljiva z lastnimi vektorji v stolpcih.

Če je *A* **simetrična** (*A*^{*T*} = *A*), so vse lastne vrednosti realne in *A* je diagonalizabilna v ortonormirani bazi (lastni vektorji različnih lastnih vrednosti so ⊥).

Matrika *A* je **pozitivno semidefinitna** (*A* ≥ 0)

⟺ vse lastne vrednosti λ ≥ 0

⟺ *x*^{*T*} *Ax* = ∑*i,j*=1^{*n*} *a*_{*ij*} *x*_{*i*} *x*_{*j*}

⟺ vse glavne poddeterminante ≥ 0

Glavne poddeterminante dobimo tako, da izbrišemo nekatere vrstice in stolpce z enakimi indeksi.

Matrika

A
=

[

a

b

c

d

]

{\displaystyle A={\begin{bmatrix}a&b\\c&d\end{bmatrix}}

 je *A* ≥ 0 ⟺ *ac* − *b*² ≥ 0 in *a* ≥ 0

Konveksne funkcije in vezani ekstremi

$$\begin{array}{ll} \min & f(x) \\ \text{p.p.} & x \in \Omega^{\text{odp}} \subseteq \mathbb{R}^n \\ & g_1(x) \leq 0 \\ & \vdots \\ & g_m(x) \leq 0 \end{array}$$

$$D=\{x\in \Omega: g_i(x)\leq 0\;\forall i=1,\ldots,m\}$$

*f, g*₁, ..., *g*_{*m*} : Ω → ℝ zvezno odvedljive

Karush–Kuhn–Tuckerjevi pogoji

Lagrangeeva funkcija

$$L(x,\lambda)=f(x)+\sum_{j=1}^m\lambda_jg_j(x)$$

x^{*} ∈ Ω zadošča pogojem KKT, če ∃λ₁, ..., λ_{*m*} ≥ 0, da velja:

$$Lx_i(x^*)=0\qquad\qquad\forall i=1,\ldots,n$$

$$\lambda_jg_j(x^*)=0\qquad\qquad\forall j=1,\ldots,m$$

$$g_j(x^*)\leq 0\qquad\qquad\forall j=1,\ldots,m$$

V splošnem KKT pogoji niso ne potrebni ne zadostni za globalni/lokalni ekstrem.

Potrebnost pogojev KKT optimalnost:
Če ima *f* v točki *x*^{*} ∈ *D* lokalni min na *D* in so vezi v *x*^{*} regularne, točka *x*^{*} zadošča pogojem KKT.

Zadostni pogoji za regularnost vezi:
Če velja vsaj en od pogojev so vezi v *x*^{*} regularne.

- g*₁, ..., *g*_{*m*} afine
- Ω konveksna, *f, g*₁, ..., *g*_{*m*} konveksne in notranjost *D*^o ≠ ∅
- vse množice vektorjev {∇*g*_{*i*}(*x*^{*}) | *g*_{*i*}(*x*^{*}) = 0} linearno neodvisne

Zadostnost pogojev KKT za optimalnost:
Ω odprta, konveksna množica, *f, g*₁, ..., *g*_{*m*} : Ω → ℝ konveksne in odvedljive
Če *x*^{*} ustreza KKT pogojem, je globalni minimum.

Za konveksni problem *z* *D*^o ≠ ∅ so KKT pogoji ⟺ *x*^{*} globalni minimum.

Celoštevilski linearni programi

$$\begin{array}{ll} \max & c^T x \\ \text{p.p.} & Ax \leq b \\ & x \geq 0 \\ & x \in \mathbb{Z} \end{array}$$