

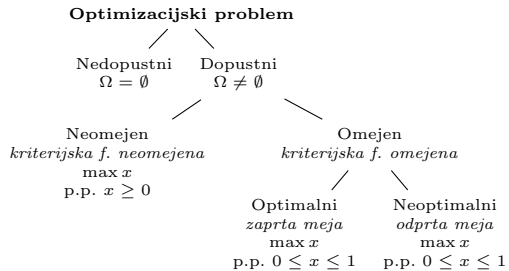
## Optimizacijske naloge

Optimizacijska naloga je  $(\Omega, f, \max/\min/\sup/\inf, )$  kjer je:

- $\Omega$  množica dopustnih rešitev
- $f : \Omega \rightarrow \mathbb{R}$  kriterijska funkcija

$x^* \in \Omega$  je *optimalna* rešitev problema  $(\Omega, f, \max)$ , če velja

$$\forall x \in \Omega : f(x) \leq f(x^*)$$



## Linearno programiranje

$(\Omega, f, \min/\max)$  je linearni porgram, če je  $\Omega$  podana z linearnimi enakostmi in neenakostmi  $(\leq, \geq)$  in je  $f$  linearna.

### Standardna oblika linearnega pograma

Linearni porgram je v *standardni* obliki, če iščemo  $\max$  in so vsi pogoji neenakosti  $\leq$  in so vse spremenljivke nenegativne.

$$\begin{array}{ll} \max & c_1 x_1 + \dots + c_n x_n \\ \text{p.p.} & a_{11} x_1 + \dots + a_{1n} x_n \leq b_1 \\ & \vdots \\ & a_{m1} x_1 + \dots + a_{mn} x_n \leq b_m \\ & x_1, \dots, x_n \geq 0 \end{array}$$

To lahko zapišemo v matrični obliki:

$$c = [c_1 \dots c_n]^T \quad b = [b_1 \dots b_m]^T \quad x = [x_1 \dots x_n]^T$$

$$A = \begin{bmatrix} a_{11} & \dots & a_{1n} \\ \vdots & & \vdots \\ a_{m1} & \dots & a_{mn} \end{bmatrix} \in \mathbb{R}^{m \times n} \quad \begin{array}{ll} \max & c^T x \\ \text{p.p.} & Ax \leq b \\ & x \geq 0 \end{array}$$

Vsak linearen program lahko zapišemo v standardni obliki.

Vse dele linearnega programa lahko preoblikujemo tako, da bodo v standardni obliki:

$$\begin{array}{ll} \min f(x) \rightsquigarrow \max(-f(x)) \\ f(x) \geq b \rightsquigarrow -f(x) \leq -b \\ f(x) = b \rightsquigarrow f(x) \leq b \wedge f(x) \geq b \\ x_i \leq 0 \rightsquigarrow x_i = -x'_i \\ x_i \geq 0 \rightsquigarrow x_i = x'_i - x''_i \wedge x'_i, x''_i \geq 0 \end{array}$$

### Grafično reševanje linearnih programov

Za linearne porgame z dvema spremenljivkama lahko narišemo območje, ki ga določajo pogoji. Nato izračunamo gradient kriterijske funkcije in premikamo v smeri gradienta proti točki, ki je v preseku polporostorov pogojev in čim dlje od izhodišča.

### Simpleksna metoda

Linearni program zapišemo v standardni obliki. Če je kak  $b_i < 0$ , moramo uporabiti **dvofazno simpleksno metodo**, sicer nadaljujemo.

Linearni porgram zapišemo v *prvi* slovar.

$$\begin{array}{c} \overbrace{x_{n+1} = b_1 - a_{11}x_1 - \dots - a_{1n}x_n}^{1. \text{ slovar}} \\ \vdots \\ \hline x_{n+m} = b_m - a_{m1}x_1 - \dots - a_{mn}x_n \\ z = c_1x_1 + \dots + c_nx_n \end{array}$$

Vse spremenljivke  $x_1, \dots, x_{n+m}$  so nenegativne.

Spremenljivke na levi so **bazne**, na desni pa **nebazne**.

$$\begin{array}{lll} x_1, \dots, x_n & \dots & \text{prvotne spremenljivke} \\ x_{n+1}, \dots, x_{n+m} & \dots & \text{dopolnilne spremenljivke} \end{array}$$

Slovar je **dopusten**, če so vse konstante (čelni brez  $x$ ) na desni nenegativne.

Če je slovar dopusten, ima *bazno* dopustno rešitev: vse *nebazne* spremenljivke so 0 in kriterijska funkcija je tedaj  $z = 0$ .

- Določimo:
  - vstopno spremenljivko**: izberem spremenljivko, ki ima v kriterijski funkciji pozitiven koeficient.
  - pivotno vrstico**: enakost, ki povečanje vstopne spremenljivke najbolj omejuje. Če ni omejena, je problem **neomejen** in končamo.
  - izstopno spremenljivko**: bazna spremenljivka v pivotni vrstici
- Iz pivotne vrstice izrazimo vstopno spremenljivko in pivotno vrstico zamenjamo z izražavo (vstopna spremenljivka gre v bazo na levo stran).
- V ostalih vrsticah in kriterijski funkciji vstopno spremenljivko nadomestimo z zgornjo izražavo.
- Dobimo naslednji slovar. Postopek ponavljamo dokler niso vsi koeficienti v kriterijski funkciji negativni ali enaki 0.

Iz zadnjega slovarja razberemo optimalne rešitve: spremenljivke, ki imajo v kriterijski funkciji negativen koeficient imajo vrednost 0, ostale pa lahko spreminjamo glede na omejitve.

### Dvofazna simpleksna metoda

Če je  $b \not\geq 0$ , uporabimo dvofazno simpleksno metodo.

#### Prva faza

Konstruiramo pomožni problem. V vsaki neenakosti  $b_i$  prištejemo  $x_0$ . Kriterijsko funkcijo pa spremenimo v  $\max -x_0$ .

Iz pomožnega problema zapišemo 1. slovar.

$$\begin{array}{c} x_{n+1} = b_1 + x_0 - a_{11}x_1 - \dots - a_{1n}x_n \\ \vdots \\ \hline x_{n+m} = b_m + x_0 - a_{m1}x_1 - \dots - a_{mn}x_n \\ w = -x_0 \end{array}$$

Za vstopno spremenljivko izberemo  $x_0$  za pivotno vrstico pa tisto v kateri je  $b_i$  najmanjši. Nato nadaljujemo z običajno simpleksno metodo.

Nadaljujemo z navadno simpleksno metodo in upoštevamo pravilo:  $x_0$  ima prednost med kandidati za izstopno spremenljivko.

Če  $w^* < 0$ , prvotni problem ni dopusten, sicer nadlajujemo z drugo fazo.

### Druga faza

Iz zadnjega slovarja pomežnega problem izberimo  $x_0$  in kriterijsko funkcijo originalnega programa izrazimo z nebaznimi spremenljivkami. Nadaljujemo z običajno simpleksno metodo.

## Dualnost pri linearnem programiranju

Vsak linearni program  $P$  ima dualno obliko  $P'$ :

$$\begin{array}{lll} \max & c^T x & \\ \text{p.p.} & Ax \leq b \\ & x \geq 0 \end{array} \implies \begin{array}{lll} \min & b^T y & \\ \text{p.p.} & A^T y \geq c \\ & y \geq 0 \end{array}$$

$$P'' = P$$

#### Šibki izrek o dualnosti - ŠID

$x$  dopustna rešitev za  $P$ ,  $y$  dopustna rešitev za  $P' \implies$

$$c^T x \leq b^T y$$

$x$  dopustna za  $P$ ,  $y$  dopustna za  $P'$  in  $c^T x = b^T y \implies$

$x$  optimalna rešitev  $P$ ,  $y$  optimalna rešitev  $P'$

#### Krepki izrek o dualnosti - KID

$x^*$  optimalna rešitev  $P \implies$

optimalna rešitev  $P'$  in  $c^T x^* = b^T y^*$

Linearni program in njegov dual sta lahko:

	nedopusten	neomejen	optimalen
nedopusten	✓	✓	//KID
neomejen	✓	//ŠID	//ŠID, KID
optimalen	//KID	//ŠID, KID	✓

#### Dualno dopolnjevanje

Naj bo  $x$  dopustna za  $P$  in  $y$  dopustna za  $P'$  tedaj je:

$x$  optimalna za  $P$  in  $y$  optimalna za  $P' \iff$

$$\forall i = 1, \dots, m : \quad \sum_{j=1}^n a_{ij} x_j = b_i \quad \text{ali} \quad y_i = 0$$

$$\forall j = 1, \dots, n : \quad x_j = 0 \quad \text{ali} \quad \sum_{i=1}^m a_{ij} y_i = c_j$$

**Ekvivalentno**:  $x$  optimalna za  $P$ ,  $y$  optimalna za  $P' \Leftrightarrow$

$$\sum_{j=1}^n a_{ij} x_j < b_i \implies y_i = 0 \quad \forall i$$

in

$$x_j > 0 \implies \sum_{i=1}^m a_{ij} y_i = c_j \quad \forall j$$

### Uporaba izreka o dualnem dopolnjevanju

Želimo dokazati, da je  $x^*$  optimalna rešitev linearnega programa  $P$ .

- Preverimo, da je  $x^*$  dopustna rešitev.
- Če je kakšna neenakost pri pogojih  $P$  izpolnjena s strogo neenakostjo, je pripadajoča dualna spremenljivka  $y_i^* = 0$ .

- Če je kaka  $x_j^* > 0$ , je pripadajoča dualna neenakost v  $P'$  izpolnjena z enakostjo:

$$\sum_{i=1}^n a_{ij} y_i = c_j$$

- Vzamemo enačbe iz 3. koraka in upoštevamo, da so nekateri  $y$  iz 2. koraka enaki 0. Rešimo dobljeni sistem (če ni rešljiv,  $x^*$  ni optimalna).

- Preverimo ali je dobljena rešitev  $y^*$  dopustna. Če je, sta  $x^*$  in  $y^*$  optimalni.

### Dual splošnega problema

Splošna oblika linearnega programa je manj stroga standardna oblika. Dovolimo, da so pogoji postavljeni  $z \leq$  lahko pa tudi  $z =$ . Poleg tega dovolimo, da nekatere spremenljivke niso omejene z  $x_j \geq 0$ .

Program v splošni obliki izgleda takole:

$$\begin{array}{lll} \max & \sum_{j=1}^n c_j x_j & \\ \text{p.p.} & \sum_{j=1}^n a_{ij} x_i \leq b_i & \forall i = 1, \dots, m' \\ & \sum_{j=1}^n a_{ij} x_i = b_i & \forall i = m' + 1, \dots, m \\ & x_i \geq 0 & \forall i = 1, \dots, n' \end{array}$$

Njegov dual pa je:

$$\begin{array}{lll} \min & \sum_{i=1}^m b_i y_i & \\ \text{p.p.} & \sum_{i=1}^m a_{ij} y_i \leq c_j & \forall j = 1, \dots, n' \\ & \sum_{i=1}^m a_{ij} y_i = c_j & \forall j = n' + 1, \dots, n \\ & y_i \geq 0 & \forall i = 1, \dots, m' \end{array}$$

$$\begin{array}{ll} \text{enakost} \xleftrightarrow{\text{dual}} \text{poljubna spremenljivka} \\ \text{neenakost} \xleftrightarrow{\text{dual}} \text{nenegativna spremenljivka} \end{array}$$

### Dualno dopolnjevanje splošnega problema

$x$  dopustna za  $P$   
 $y$  dopustna za  $P'$   
 $x$  optimalna za  $P$  in  $y$  optimalna za  $P' \Leftrightarrow$

$$\forall i = 1, \dots, m' : \quad \sum_{j=1}^n a_{ij} x_j = b_i \quad \text{ali} \quad y_i = 0$$

$$\forall j = 1, \dots, n' : \quad x_j = 0 \quad \text{ali} \quad \sum_{i=1}^m a_{ij} y_i = c_j$$

### Ekonomski pomen dualnih spremenljivk

Naj bo  $P$  linearni program,  $\exists$  neizrojena optimalna rešitev (v zadnjem slovarju so vse konstante  $> 0$ ). Potem  $\exists \varepsilon > 0$ , da velja

$$\Delta z^* = \sum_{i=1}^m y_i^* \Delta b_i$$

kjer je  $y^*$  optimalna rešitev duala,  $\Delta z^*$  sprememba optimalne vrednosti,  $\Delta b_i$  pa sprememba dense strani pogojev in  $|\Delta b_i| < \varepsilon$ .

Torej če desni strani pogojev v  $P$  prištejemo dovolj majhen  $\Delta b$ , se optimalna vrednost  $z^*$  programa  $P$  spremeni za  $\Delta z^* = \Delta b^T y^*$ .

$y^*$  nam tedaj da "tržno ceno" dobrin. Če želimo povečati dobrino  $b_i$ , se nam dobiček poveča za  $b_i y_i^*$ . Torej za enoto dobrine  $i$  ne smemo plačati več kot  $y_i^*$ .

Umetne (dodane) povezav imajo ceno 1, prvotne pa 0.  
Prvotni problem je dopusten  $\iff$  vrednost pomožnega problema enaka 0.

$$A \subset A^{**}$$

## Farkaševa lema

**Geometrijska oblika:**

$$S^{**}(a_1,\ldots,a_n)=S(a_1,\ldots,a_n)$$

**Algebraična oblika:**

*Prva varianta:*

$$\exists x \geq 0: Ax=b \iff \forall y: A^Ty \geq 0 \implies b^Ty \geq 0$$

$$b \in S(a_1,\ldots,a_n) \iff b \in S^{**}(a_1,\ldots,a_n)$$

*Druga varianta:*

$$\exists x \geq 0: Ax \leq b \iff \forall y \geq 0: A^Ty \geq 0 \implies b^Ty \geq 0$$

### Konveksne funkcije

Naj bo *K*<sup>konv</sup> ⊆ ℝ<sup>n</sup>; funkcija *f* : *K* → ℝ je konveksna, če

$$\forall x,y \in K \, \forall \lambda \in [0,1]: \\ f((1-\lambda)x+\lambda y) \leq (1-\lambda)f(x)+\lambda f(y)$$

*Funkcija je konveksna, če je definirana na konveksnem območju in graf vedno leži pod zveznico dveh točk na grafu.*

Če zgoraj velja stroga neenakost, je funkcija **strogo konveksna**.

*f* strogo konveksna  ⇔  *H*<sub>*f*</sub> > 0.

Če ima strogo konveksna funkcija maksimum, je v *ekstremni točki*.

### Konkavne funkcije

Naj bo *K*<sup>konv</sup> ⊆ ℝ<sup>n</sup>; funkcija *f* : *K* → ℝ je konkavna, če

$$\forall x,y \in K \, \forall \lambda \in [0,1]: \\ f((1-\lambda)x+\lambda y) \geq (1-\lambda)f(x)+\lambda f(y)$$

Če je *f* konveksna, je −*f* konkavna.

Funkcija *f* je **afina**  ⇔  konveksna in konkavna

- f* : *K* → ℝ, *c* ≥ 0, *f* konveksna  ⇒  *c* · *f* konveksna
- f, g* : *K* → ℝ, *f, g* konveksni  ⇒  *f* + *g* konveksna
- g* : *K* → ℝ<sup>n</sup> afina  ⇒  *g*(*K*) konveksna
- f* : *g*(*K*) → ℝ konveksna  ⇒  *f* o *g* konveksna
- g* : *K* → ℝ, *f* : Conv(*g*(*K*)) → ℝ, *f, g* konveksni
- f* naraščujoča  ⇒  *f* o *g* konveksna

#### Konveksne funkcije in optimizacija

Naj bo *A* ⊆ ℝ<sup>n</sup> in *f* : *A* → ℝ.

- f* ima v *x* ∈ *A* **globalni maksimum**, če

$$\forall x' \in A: \; f(x) \geq f(x')$$

- f* ima v *x* ∈ *A* **lokalni maksimum**, če

$$\exists \varepsilon > 0: \; \forall x' \in A \cap K_\varepsilon(x): \; f(x) \geq f(x')$$

Če je *x* lokalni minimum konveksne funkcije, je tudi globalni minimum.

#### Preverjanje konveksnosti funkcije

**S** prvim odvodom

*f* : *K*<sup>konv</sup>, odp → ℝ odvedljiva

$$f \; \text{konveksna} \iff f(y) \geq f(x) + (\nabla f(x))^T (y-x)$$

**Z** drugim odvodom

*f* : Ω<sup>odp</sup> ⊆ ℝ<sup>n</sup> → ℝ dvakrat zvezno odvedljiva

Hessejeva matrika:

$$H_f=\left[\frac{\partial^2 f}{\partial x_i \partial x_j}\right]_{i,j=1}^n$$

$$f \; \text{konveksna} \iff H_f \geq 0$$

*f* : Ω → ℝ konveksna  ⇔  *h*<sub>*x,y*</sub> : *I*<sub>*x,y*</sub> → ℝ, *h*<sub>*x,y*</sub>(λ) = *f*(*x* + λ*y*), konveksna za ∀*x* ∈ ℝ ∀*y* ∈ ℝ<sup>n</sup> *I*<sub>*x,y*</sub> = {λ ∈ ℝ : *x* + λ*y* ∈ Ω}

\_\_\_\_\_

**Lastne vrednosti** matrike *A* so ničle karakterističnega polinoma *det*(*A* − λ*I*).

**Lastni podprostor** vrednosti λ je Ker(*A* − λ*I*) \ {0}.

*A* ∈ ℝ<sup>*n* × *n*</sup> je **diagonalizabilna**, če ima *n* linearno neodvisnih lastnih vektorjev. Tedad je *A* = *PDP*<sup>−1</sup>, kjer je *D* diagonalna z lastnimi vrednostmi na diagonali, *P* pa obrnljiva z lastnimi vektorji v stolpcih.

Če je *A* **simetrična** (*A*<sup>*T*</sup> = *A*), so vse lastne vrednosti realne in *A* je diagonalizabilna v ortonormirani bazi (lastni vektorji različnih lastnih vrednosti so ⊥).

Matrika *A* je **pozitivno semidefinitna** (*A* ≥ 0)

⇔ vse lastne vrednosti λ ≥ 0

⇔ *x*<sup>*T*</sup> *Ax* = ∑<sub>*i,j*=1</sub><sup>*n*</sup> *a*<sub>*ij*</sub> *x*<sub>*i*</sub> *x*<sub>*j*</sub>

⇔ vse glavne poddeterminante ≥ 0

*Glavne poddeterminante dobimo tako, da izbrišemo nekatere vrstice in stolpce z enakimi indeksi.*

Matrika 



A
=



[



a


b


c


d



]


{\displaystyle A={\begin{bmatrix}a&b\\c&d\end{bmatrix}}

 je *A* ≥ 0 ⇔ *ac* − *b*<sup>2</sup> ≥ 0 in *a* ≥ 0

### Konveksne funkcije in vezani ekstremi

$$\begin{array}{ll} \min & f(x) \\ \text{p.p.} & \begin{array}{l} x \in \Omega^{\text{odp}} \subseteq \mathbb{R}^n \\ g_1(x) \leq 0 \\ \qquad \vdots \\ g_m(x) \leq 0 \end{array} \end{array}$$

$$D=\{x\in \Omega: g_i(x)\leq 0\;\forall i=1,\ldots,m\}$$

*f, g*<sub>1</sub>, ..., *g*<sub>*m*</sub> : Ω → ℝ zvezno odvedljive

#### Karush–Kuhn–Tuckerjevi pogoji

**Lagrangeeva funkcija**

$$L(x,\lambda)=f(x)+\sum_{j=1}^m\lambda_jg_j(x)$$

*x*<sup>\*</sup> ∈ Ω zadošča pogojem KKT, če ∃λ<sub>1</sub>, ..., λ<sub>*m*</sub> ≥ 0, da velja:

$$Lx_i(x^*)=0\qquad\qquad\forall i=1,\ldots,n$$

$$\lambda_jg_j(x^*)=0\qquad\qquad\forall j=1,\ldots,m$$

$$g_j(x^*)\leq 0\qquad\qquad\forall j=1,\ldots,m$$

\_\_\_\_\_

*V splošnem KKT pogoji niso ne potrebni ne zadostni za globalni/lokalni ekstrem.*

**Potrebnost pogojev KKT optimalnost:**

Če ima *f* v točki *x*<sup>\*</sup> ∈ *D* lokalni min na *D* in so vezi v *x*<sup>\*</sup> regularne, točka *x*<sup>\*</sup> zadošča pogojem KKT.

**Zadostni pogoji za regularnost vezi:**

Če velja vsaj en od pogojev so vezi v *x*<sup>\*</sup> regularne.

- g*<sub>1</sub>, ..., *g*<sub>*m*</sub> afine

- Ω konveksna, *f, g*<sub>1</sub>, ..., *g*<sub>*m*</sub> konveksne in notranjost *D*<sup>o</sup> ≠ ∅

- množica vektorjev {∇*g*<sub>1</sub>(*x*<sup>\*</sup>), ..., ∇*g*<sub>*m*</sub>(*x*<sup>\*</sup>)} je linearno neodvisna

**Zadostnost pogojev KKT za optimalnost:**

Ω odprta, konveksna množica, *f, g*<sub>1</sub>, ..., *g*<sub>*m*</sub> : Ω → ℝ konveksne in odvedljive

Če *x*<sup>\*</sup> ustreza KKT pogojem, je globalni minimum.

Za konveksni problem *z* *D*<sup>o</sup> ≠ ∅ so KKT pogoji

⇔ *x*<sup>\*</sup> globalni minimum.

## Celoštevilski linearni programi

$$\begin{array}{ll} \max & c^T x \\ \text{p.p.} & \begin{array}{l} Ax \leq b \\ x \geq 0 \\ x \in \mathbb{Z} \end{array} \end{array}$$